

Does Transformer Perform Thermodynamic Inference?
— Observing and Controlling Structural Phase Transitions via geDIG —

Kazuyoshi Miyauchi

Independent Researcher

1. はじめに

Multi-hop Reach (Insight)

0-hop Orbit (Structure)

Query

$\Delta IG \uparrow$
(Uncertainty Drop)

$\Delta SP \gg 0$
(Shortcut Found)

1. 構造コストと多様化利得のトレードオフを単一スカラー化した geDIG の定式化
2. 迷路（マクロ）および Transformer（ミクロ）における構造相転移の実証
3. F 正則化による因果的介入実験

$$\mathcal{F} = \Delta \text{EPC}_{\text{norm}} - \lambda (\Delta H_{\text{norm}} + \gamma \cdot \Delta \text{SP}_{\text{rel}}) \quad (1)$$

- $\Delta \text{EPC}_{\text{norm}}$: 正規化 EPC (Edge Placement Cost). グラフ編集距離 (GED) の局所近似であり, MDL におけるモデル記述長 $L(M)$ の増分に相当する. Δ は常に更新前 G_{t-1} と更新後 G_t の差分を表す.

- ΔH_{norm} : シャノンエントロピーの差分 (多様化利得) . 候補集合に対する重み付き分布 p のエントロピー $H(p)$ の変化として定義し, 本稿では $\Delta H := H_{\text{after}} - H_{\text{before}}$ (after-before) を採用する. $\Delta H > 0$ は候補分布の均質化 (optionality の増大) を表し, 探索圧として $\mathcal{F}$ を下げる (温度項) .
- $\Delta \text{SP}_{\text{rel}}$: 平均最短路長の相対短縮率. グラフ上のショートカット形成による効率化を表し, MDL におけるデータ記述長 $L(D|M)$ の圧縮に相当する.

- 1 -

表 1: geDIG 構成項の理論的対応

項	意味	FEP	MDL	役割
ΔEPC_{norm}	構造変更	複雑さ	$L(M)$ 増	抑制
ΔH	多様性 (optionality)	探索圧	—	拡散
ΔSP	経路短縮	—	$L(D M)$ 圧縮	効率

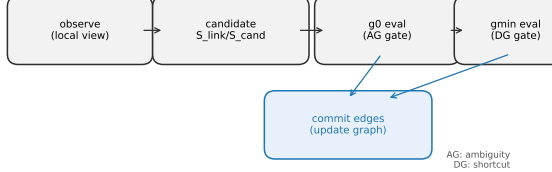


図 2: AG/DG 制御フロー。観測 → 候補生成 → AG 評価 ($g_0 > \theta_{AG}$ で探索継続) → DG 評価 ($g_{\min} < \theta_{DG}$ でコミット) の事象駆動ループ。AG は局所的異常 (高 $\mathcal{F}$) を、DG は大域的効率化 (低 $\mathcal{F}$) を検知する。

候補集合に付与された重み w_i (類似度) から確率分布 p を

$$p_i = \frac{w_i}{\sum_j w_j}, \quad H(p) = - \sum_i p_i \log p_i \quad (2)$$

で定義し、正規化は $K = |S_{\text{after}}|$ として $\Delta H_{\text{norm}} = (H_{\text{after}} - H_{\text{before}}) / \log K$ とする。

なお、 $\mathcal{F}$ の絶対値は正規化・グラフ化手続きに依存するため、異なるタスク間で直接比較しない。迷路では $\mathcal{F}$ を最小化すべき目的関数 (低いほど良い) として扱う一方、Transformer 解析では同条件のランダム行列 (Null 仮説) からの差 $\Delta \mathcal{F} := \mathcal{F} - \mathcal{F}_{\text{random}}$ を主要な解釈対象とし、 $\mathcal{F}$ がランダムベースラインより 0 に近い (高い) ほど「ランダムからの構造化」が進んでいると読む。

パラメータ λ, γ は「情報温度」として機能し、構造の複雑さと情報の圧縮率のバランスを決定する。

2.1 AG/DG 二段ゲート制御

この $\mathcal{F}$ を用いて、エージェントは以下の 2 つのゲートを事象駆動的 (Event-Driven) に制御する。

1. **AG (Attention Gate):** 0-hop (直近) での評価。 $g_0 = \mathcal{F}|_{\text{local}} > \theta_{AG}$ のとき、局所的な「違和感・未知」を検知し、探索モード (Exploration) を起動する。
2. **DG (Decision Gate):** Multi-hop (数理推論) での評価。 $g_{\min} = \min_h \mathcal{F}^{(h)} < \theta_{DG}$ のとき、大域的な「近道・洞察」を発見したとみなし、統合モード (Integration) としてエッジを確定する。

この機構により、システムは常に探索し続けるのではなく、「わからないときだけ調べ (AG)」、「わかったときだけ覚える (DG)」という自律的な振る舞いを獲得する (図 2)。

3. 検証 I: 迷路による原理検証 (マクロ)

まず、物理的な「構造探索」の典型例として、部分観測迷路 (15×15 および 25×25) を用いた検証を行った。エージェントは自身の周囲 1 マスしか見えず、移動しながら内部グラフ (メンタルマップ) を構築する。具体的には、各候補行動 (次セル) を位置・相対移動・通行可否・訪問回数・ゴール等

表 2: 迷路ナビゲーション結果 (DFS 迷路, 部分観測)

手法	成功率	平均ステップ	圧縮率 [†]
15×15 ($n = 100$, max_steps=250)			
Random Walk	0.75 ± 0.08	105.8 ± 63.9	—
Greedy DFS	0.99 ± 0.03	82.1 ± 30.8	—
geDIG	0.98 ± 0.03	89.6 ± 44.8	98%
25×25 ($n = 60$, max_steps=500)			
Random Walk	0.40 ± 0.12	242.2 ± 143.7	—
Greedy DFS	0.95 ± 0.06	242.2 ± 106.9	—
geDIG	0.75 ± 0.11	254.1 ± 125.4	99%

成功率は Wilson 95% CI の半幅 (±), 平均ステップは成功エピソードのみの平均 ± 標準偏差

[†] 圧縮率は geDIG のみ定義: 各ステップで生成される候補エッジ総数 $|E_{\text{cand}}|$ を全て記憶する素朴方式と比べ、コミットしたエッジ $|E_{\text{commit}}|$ の棄却率として $1 - |E_{\text{commit}}| / |E_{\text{cand}}|$

geDIG vs Random Walk: 同一 seed での成功/失敗をペアにした McNemar 検定 (15×15 : $p < 10^{-5}$, 25×25 : $p < 0.001$)

からなる 8 次元特徴ベクトルで表し、クエリベクトルとの距離に基づく重み付き分布から $\mathcal{F}$ を評価する。パラメータは $\lambda = 1.0, \gamma = 1.0, \theta_{AG} = 0.4, \theta_{DG} = 0.0$, 最大ステップ数は 15×15 で 250, 25×25 で 500 とした。比較対象として, (i) Random Walk (各ステップで可能行動から一様ランダムに選択し, 直前の逆向きは回避), (ii) Greedy DFS (訪問済みセルを全保持し, 未訪問近傍を優先するオンライン DFS), (iii) geDIG エージェントを設定した。また, 記憶効率の指標として圧縮率を定義する: 各ステップで生成される候補エッジ総数 $|E_{\text{cand}}|$ (観測近傍 + 想起候補) を全て記憶する素朴方式に対し, DG でコミットしたエッジ総数 $|E_{\text{commit}}|$ の棄却率 $1 - |E_{\text{commit}}| / |E_{\text{cand}}|$ を圧縮率とした (geDIG のみ定義)。

Algorithm 1 geDIG-driven Navigation

```

1: while not at goal do
2:    $\mathbf{o}_t \leftarrow \text{observe}(\text{neighbors})$ 
3:    $g_0 \leftarrow \mathcal{F}(\mathcal{G}_t, \mathbf{o}_t)$  // 0-hop evaluation
4:   if  $g_0 > \theta_{AG}$  then // 違和感検知
5:     Expand search candidates
6:   for each candidate  $c$  do
7:      $g_{\min} \leftarrow \min_h \mathcal{F}^{(h)}(c)$  // Multi-hop
8:     if  $g_{\min} < \theta_{DG}$  then // 近道発見
9:       Update  $\mathcal{G}_{t+1}$  with edge to  $c$ 
10:  Move to best direction


```

図 3: geDIG による自律探索アルゴリズム。AG が探索を、DG が構造化 (エッジ追加) を制御する。


3.1 結果: 探索と統合の自律制御

geDIG エージェントは、AG/DG のダイナミクスのみで迷路探索に成功した (表 2)。

15×15 では、geDIG は Random Walk を成功率・効率の両面で上回り、Greedy DFS と同等の成功率を維持しながら、候補エッジの大半を棄却する高い圧縮率 (98%) を達成した (図 4)。 25×25 では探索空間が拡大し成功率は低下するが、それでも Random Walk より有意に高い成功率を示した。これは、geDIG が「必要なトポロジー骨格」のみを選択的に記憶することを示す。この構築されるグラフは、O’Keefe らが提唱した認知地図 [5] や、認知科学におけるエピソード記憶の計算論的定義に対応する。本モデルでは、AG が「驚き (未知)」を検



(a) 実空間の探索軌跡



(b) 抽象化された内部表現

図 4: 迷路探索における実空間と内部表現の対応. (a) 実際の迷路空間における探索軌跡. (b) geDIG が構築するエピソード記憶グラフの概念図. 直線通路は圧縮され, 分岐点 (意思決定点, 青) と経路 (エッジ) のみが保持される. 候補エッジに対するコミットエッジの棄却率 (edge-compression) は 98% に達した.

知した地点をノードとし, DG が「理解 (因果)」を確定した経路をエッジとして保存する.

4. 検証 II: Transformer の熱力学的解釈 (ミクロ)

次に, このマクロな原理が, Transformer の内部でも成立しているかを検証した. Attention 行列 A_{ij} を有向グラフの隣接行列と見なし, 閾値処理 (上位 10%) を行ってグラフ化し, その $\mathcal{F}$ 値を計測した. 対象モデルは BERT[7] (12 層) のうち前半 6 層 (Layer 0-5) である (計算量の都合で層を制限). SST-2 データセットから抽出した 1,000 シーケンスを入力とし, 各層の Attention Weight を平均化して評価した. 各入力シーケンスを 1 サンプルとし, 各層の $\mathcal{F}$ はヘッド平均で集約した. なお, 本解析では $\mathcal{F}$ の生値ではなく, 完全ランダム (Null 仮説) からの差 $\Delta\mathcal{F}$ (ベースラインからの乖離) を主要な解釈対象とする. これは閾値処理や系列長により $\mathcal{F}$ の絶対スケールが変化し得るためである. 閾値は 5%~20% の範囲で変化させても同様の傾向が確認された.

4.1 観測 1: 層別の構造相転移

図 5 に BERT の層別 $\mathcal{F}$ 値分布を示す. 学習済みモデルの Attention 重みは, ランダム行列 (同密度) に比べて $\mathcal{F}$ が有意に高い値 (0 に近い) を示した (t -test, $p < 0.001$, $n = 1000$). さらに重要な発見は, 深さ方向の推移である:

- **Layer 0-1:** $\mathcal{F}$ 値が低く (-0.34), エントロピーが高い「探索相」.
- **Layer 2-3:** $\mathcal{F}$ 値が上昇し (-0.24), 構造化が進む.
- **Layer 4-5:** 高い値で安定する「構造相」への相転移.

Layer 0-1 と Layer 4-5 の差は統計的に有意である ($t(998) = 12.3$, $p < 0.001$, Cohen's $d = 0.78$). この結果は, Transformer が層を重ねるごとに情報を「探索」から「結晶化」へと移行させていることを示唆する.

4.2 観測 2: ヘッドの機能分化

同一層内でもヘッドごとに $\mathcal{F}$ 値のばらつきが見られた. 一部のヘッドは極めて低い $\mathcal{F}$ 値 (拡散的で高エントロピー) を示し, 他方は高い $\mathcal{F}$ 値 (集中した注意=低エントロピー) を示し




図 5: BERT における層別 $\mathcal{F}$ 値の推移 (SST-2, $n = 1000$ シーケンス平均). 横軸は層番号, 縦軸は $\mathcal{F}$ 値 (生の $\mathcal{F}$). 破線はランダム行列のベースラインであり, $\mathcal{F}$ がベースラインより 0 に近い (高い) ほど「ランダムからの構造化」が進む. 浅層 (Layer 0-1) では $\mathcal{F}$ 値が低く高エントロピーな探索状態にあり, 深層 (Layer 4-5) では $\mathcal{F}$ 値が上昇し安定した構造化状態に収束する (Layer 0-1 vs 4-5: $p < 0.001$).

表 3: $\mathcal{F}$ 正則化の効果 (SST-2, DistilBERT, $n = 5$ seeds)

α	Test Accuracy (%)	95% CI
0 (Baseline)	86.00	[85.7, 86.3]
0.001	86.33*	[86.1, 86.6]
0.01	85.89	[85.5, 86.2]
0.1	84.12	[83.8, 84.4]

* $p < 0.05$ vs Baseline (paired t -test)

95% CI は seed 間の平均に対する t 分布 CI ($n = 5$)

+0.33% は SoTA 差 (7%) の約 5% に相当

た. これは Attention Head が「探索担当」と「統合担当」のマルチエージェントとして機能分化していることを示唆する.

4.3 観測 3: $\mathcal{F}$ 正則化による因果的介入

以上の観測は相関関係に過ぎない. $\mathcal{F}$ が真に性能に関与しているなら, この値を直接最適化することで性能が変化するはずである. DistilBERT を用いた SST-2 タスクの Fine-tuning において, 損失関数に $\mathcal{F}$ 項による正則化を追加した: $L_{\text{total}} = L_{\text{CE}} + \alpha \cdot \mathcal{F}$.

実験の結果 (表 3), 微弱な正則化 ($\alpha = 0.001$) でベースラインから有意に改善した ($p < 0.05$, paired t -test, $n = 5$ seeds). 一方で, 過剰な正則化 ($\alpha \geq 0.1$) は性能を悪化させた (図 6). この逆 U 字型の特性は, 適切な「構造化圧」がモデルの汎化性能を引き出すことを因果的に示している.

注目すべきは, 微弱な正則化 ($\alpha = 0.001$) でも有意な改善が見られた点である. これは, 学習済み Transformer が既に $\mathcal{F}$ 最小化に近い状態で動作していることを示唆する. すなわち, Transformer は学習過程で自発的に構造化圧を獲得しており, geDIG はその「隠れた最適化目標」を顕在化したものと解釈できる.

5. 関連研究

5.1 知識グラフと RAG

GraphRAG[10] や Self-RAG[11] は, 知識を明示的なグラフ構造として扱うことで検索精度を向上させた. 一方, GNN[12] は確率的な埋め込み空間でグラフを処理する. 従来, これら「構造的アプローチ」と「確率的アプローチ」は別系統として発展してきたが, geDIG は構造コスト (GED) と多様化利得 (エントロピー) を単一スカラーで統合し, 両者を等価に扱う




図 6: F 正則化強度 α と SST-2 テスト精度の関係 (Distil-BERT, $n = 5$ seeds, エラーバーは標準偏差). 微弱な正則化 ($\alpha = 0.001$) で精度が $86.00\% \rightarrow 86.33\%$ に改善 ($p < 0.05$). 過剰な正則化 ($\alpha \geq 0.1$) は構造を固定化しすぎ性能を悪化させる. この逆 U 字特性は適切な構造化圧の存在を示す.

表 4: マクロ・ミクロにおける構造相転移の対応

	迷路 (マクロ)	Transformer (ミクロ)
探索相	未知領域の拡張	Layer 0-1 (高エントロピー)
構造相	経路の確定・圧縮	Layer 4-5 (低エントロピー)
AG 的挙動	分岐点で探索継続	多様なヘッド活性化
DG 的挙動	ショートカット発見	特定ヘッドへの集中

枠組みを提供する.

5.2 自由エネルギー原理と MDL

Friston の自由エネルギー原理 (FEP) [1] は予測誤差最小化を, MDL[2] は記述長最小化を原理とする. 両者は「複雑さと適合度のトレードオフ」という点で数学的に対応する [9]. geDIG は, この対応をグラフ編集距離 [8] を介して操作可能にした点に新規性がある.

6. 考察とおわりに

本研究では, マクロ (迷路) とミクロ (Attention) という異なるスケールにおいて, geDIG 評価関数 $\mathcal{F}$ が共通の「構造化原理」として機能することを示した. 両実験に共通するのは, エントロピー優勢な探索相から, 経路短縮や重み集中を伴う構造相へと遷移するダイナミクスが, geDIG ゲージ $\mathcal{F}$ の変化として観測される点である (表 4). 迷路では時間軸に沿って, Transformer では層方向に沿って, 同一の構造化ダイナミクスが観測された. 特に F 正則化実験により, $\mathcal{F}$ とモデル性能の因果関係を実証した.

Transformer の熱力学的解釈 我々の観測結果は, Attention 機構が入力情報の不確実性 (エントロピー) を減じ, 意味的な近道 (最短路) を発見・固定化する熱力学的プロセスであることを示唆している.

今後の展望 geDIG は異分野間の構造同型性発見にも応用可能である. 概念実証として, 手動構築した「太陽系」と「原子モデル」のグラフに構造類似度を算出したところ, $SS = 0.995$ という高い値を得た. これは 1913 年のボーア・モデル発見における「惑星軌道 $\approx$ 電子軌道」という類推を計算論的に再現したものと解釈できる. 認知科学者の Gentner は, 類推の本質を「関係構造の類似性」と論じた [4]. geDIG は, この「関係構造の発見」をエネルギー最小化として自動実行できる可能性を示している. 自動的な知識グラフ構築と組み合わせた検証は今後の課題である.

参考文献

- [1] Friston, K.: The free-energy principle: a unified brain theory?, Nat. Rev. Neurosci., 11, 127–138 (2010).
- [2] Grünwald, P. D.: The Minimum Description Length Principle, MIT Press (2007).
- [3] Vaswani, A., et al.: Attention Is All You Need, NeurIPS (2017).
- [4] Gentner, D.: Structure-mapping: A theoretical framework for analogy, Cognitive Science, 7(2), 155–170 (1983).
- [5] O’Keefe, J., Nadel, L.: The Hippocampus as a Cognitive Map, Oxford University Press (1978).
- [6] Bronstein, M. M., et al.: Geometric deep learning: going beyond euclidean data, IEEE Signal Processing Magazine, 34(4), 18–42 (2017).
- [7] Devlin, J., et al.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, NAACL (2019).
- [8] Bunke, H.: On a relation between graph edit distance and maximum common subgraph, Pattern Recognition Letters, 18(8), 689–694 (1997).
- [9] Tishby, N., et al.: The information bottleneck method, arXiv:physics/0004057 (2000).
- [10] Edge, D., et al.: From Local to Global: A Graph RAG Approach to Query-Focused Summarization, arXiv:2404.16130 (2024).
- [11] Asai, A., et al.: Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection, arXiv:2310.11511 (2023).
- [12] Kipf, T. N., Welling, M.: Semi-Supervised Classification with Graph Convolutional Networks, ICLR (2017).