

動的知識グラフの探索・統合を制御する統一ゲージの提案

Gauge what Knowledge Graph needs.

宮内 和義 (Kazuyoshi Miyauchi)

Independent Researcher miyauchikazuyoshi@gmail.com github.com/miyauchikazuyoshi/InsightSpike-AI

1. 本研究の問い: When 問題

動的知識グラフにおける根本問題: エージェントが新しい情報に出会ったとき、「いつ受け入れ、いつ探索を続けるべきか?」

従来: KL / ELBO / FEP / MDL 等の確率的評価. 構造項と確率項を分離せず, 位相的变化を暗黙的にしか扱えない.

本研究: 構造コストと情報利得を独立項としてスカラー化し, 単一ゲージ $\mathcal{F}$ で定量化.

$$\mathcal{F} = \Delta\text{EPC} - \lambda(s \cdot \Delta H + \gamma \cdot \Delta\text{SP})$$

2 段階ゲート AG/DG により $\mathcal{F}$ の符号で受け入れ / 保留 / 拒否 の 3 判定.

貢献 3 点: (1) SP 定義改善 (CLS 集中度), (2) entropy_sign s 導入, (3) 介入実験による因果検証.

98%
Maze ゴール到達率

15 × 15 grid, 250 steps


4.6%
Transformer
介入差

Positive - Negative
(因果的実証)

18K
OCR params
→ 73.53%

外部プロジェクトでの実証

2. Why three terms? — AG/DG 二段ゲートと 3 判定



2 段階ゲートの必然性

Query Q (Transformer の CLS, 迷路のゴール) を中心に, geDIG は 2 段階で新情報を評価する.

- AG (内側円, 0-hop): 近傍の曖昧性を検知. $g_0 = \Delta\text{EPC} - \lambda \cdot \Delta H$ の大小で発火.
- DG (外側円, multi-hop): 遠方への短絡が有効か確認. $\Delta\text{SP} \gg 0$ なら発火.

AG だけでは全探索になりコスト爆発, DG だけでは新発見不能. 2 段階組み合わせで曖昧性検知 → 有効性検証の流れを作る.

3 ケースの判定 (Figure 1 参照)

- Case A: Insight $\Delta\text{SP}=+1, F<0$
Multi-hop 圏に新短絡が張られる. CLS への新経路発見.
→ DG 発火 → 受け入れ (§5B の Positive 介入と対応)
- Case B: 力仕事 $\Delta\text{SP}=0, F\approx 0$
0-hop 圏内の編集. CLS 集中度に寄与しない.
→ 発火なし → 保留
- Case C: 崩壊 $\Delta\text{SP}=-1, F>0$
既存の Multi-hop 短絡が消失. CLS への有効経路断絶.
→ 逆発火 → 拒否 (§5B の Negative 介入と対応)

なぜ位相項 ΔSP が必要か

Case A/B/C は同じ編集コスト ($\Delta\text{EPC}=1$) かつ類似の情報量変化 (ΔH) でも, CLS への経路集中度 ΔSP が $+1/0/-1$ に分岐する. 確率的評価 (KL 等) は ΔSP の情報を見逃す.

→ 位相項を独立に F に組み込むことで, 質的に異なる 3 判定が初めて工学的に実現される. これが geDIG の When 問題への解法.

3. Formulation: $\mathcal{F}$ の定義

$$\mathcal{F} = \Delta\text{EPC} - \lambda(s \cdot \Delta H + \gamma \cdot \Delta\text{SP})$$

項	意味
ΔEPC	構造変更コスト (編集距離)
ΔH	情報量変化 (Shannon)
ΔSP	Shortcut Purity 変化 (CLS への経路集中度)
λ, γ	重み係数 (分位点校正)
s	entropy_sign (± 1)

$\mathcal{F} < 0$: 受け入れ (コストに見合う更新)

$\mathcal{F} \approx 0$: 保留

$\mathcal{F} > 0$: 拒否

4. entropy_sign s : 学習フェーズ適応

学習フェーズによって ΔH の望ましい方向が異なる:

フェーズ	s	解釈
構築 (迷路, 事前学習)	+1	延伸 = 利得
特化 (Fine-tuning)	-1	集中 = 利得

これにより,

- 空間 KG (迷路, 構築)
- 意味 KG (Transformer, 特化)

を同一ゲージで評価できる.

単一数式 $\mathcal{F}$ と s の組合せで 2 ドメイン統一.

5A. Spatial KG: 迷路ナビゲーション

設定: 15 × 15 grid, 部分観測, 250 steps, $s = +1$ (構築フェーズ).

結果:

指標	値
ゴール到達率	98%
候補エッジ拒否率	98%
AG/DG 発火	デッドエンド/ループ閉鎖と一致


観察: AG はデッドエンドで即座に発火, DG はループ閉鎖時に圧縮を実行. $\mathcal{F}$ の定性的な動作が理論予測と一致.

注: 単一設定 (15 × 15) の結果. 3-seed 以上の統計的検証は Future Work.

5B. Semantic KG: Transformer 介入実験

設定: DistilBERT / SST-2, $s = -1$ (特化フェーズ), Positive / Negative 介入で $\mathcal{F}$ の方向を操作.

介入実験結果 (accuracy):



Positive - Negative = 4.6% の精度差

→ $\mathcal{F}$ は因果的な学習シグナル (観測でなく介入で実証).

注: 単一 seed の結果. 3-seed 再現 + 他モデル (BERT-base) 拡張を計画.

6. Discussion: $\text{SP} \rightarrow \beta_1$ への一般化

7. 外部実証: 視覚処理 (OCR)