

1 When 問題: 動的 KG は「いつ覚えるか」を持っていない

GraphRAG や Self-RAG は 何を検索するか を最適化する。一方で、動的に成長する知識グラフでは、新規エピソードを 構造として統合するか、探索を続けるか、棄却するか を判断する原理が必要になる。

THIS PAPER

入力 came ときの評価、つまり Wake 相 の探索/統合制御を F で実証する。

NEXT TARGET

入力がないとき、記憶グラフ自身を整理する Sleep 相 へ拡張する。

2 提出論文の主要結果

Spatial KG / Maze

98% success

15×15 で候補エッジの 98% を棄却しつつ到達

Semantic KG / Transformer

p < 10⁻⁸⁰

BERT 層方向に探索相から構造相への遷移

Causal intervention

+0.33 pp

弱い F 正則化で DistilBERT/SST-2 が改善 (p = 0.038)

3 統一評価関数 F


- 更新評価: 何を覚えるかではなく、いつ構造に入れるか



- F の3項: 更新コストと利得を同じスカラーで比較

$$F = \Delta EPC_{\text{norm}} - \lambda(\Delta H_{\text{norm}} + \gamma \cdot \Delta SP_{\text{rel}})$$


F はタスク内の相対比較として用いる。ΔSP は構造利得であり、迷路では「近道」がその利得として現れる。



ΔEPC: 更新コスト

新しいノード/エッジを足すほど構造変更は重くなる。


定義: グラフ編集距離の正規化値。迷路では新規通路/想起接続、Transformer では Attention 変化を測る。



ΔH: 探索余地

候補分布が広がるほど、探索すべき不確実性が増える。

定義: 候補分布のエントロピー増分。迷路では行動候補の多様性、Transformer では Attention 拡散に対応する。





ΔSP: 構造利得

候補エッジが構造全体を圧縮するほど利得が大きい。迷路では近道になる。

定義: 平均最短路長の相対短縮。局所的な接続が全域構造をどれだけ効率化するかを測る。

- AG/DG判定: 局所候補を大域構造でコミットするか決める

AG 内で見つかった候補エッジを、DG の multi-hop 範囲で「構造利得があるか」として判定する。



4 Wake 相: AG/DG による段階的判定

多数の候補をすべて大域評価すると高コストになる。geDIG は 0-hop の局所評価で違和感を検出し、必要な場合だけ multi-hop で近道を確認する。

observe

現在状態と近傍をエピソード化

candidate

候補移動・候補エッジを生成

AG: 0-hop

局所の未知・曖昧さを検出

DG: multi-hop

近道なら記憶へコミット

物理的な移動 と 記憶グラフへの恒久保存 は別である。DG を通った接続だけが認知地図の骨格として残る。


5 Maze: なぜ部分観測で解けるのか

移動エピソードベクトル

8D: 位置、相対移動、通行可否、訪問回数、success/goal。クエリベクトルとの重み付き距離から候補分布を作る。

weights = pos 1,1 / dir 0,0 / wall 6 / visit 4 / success,goal 0,0。ゴール座標・正解経路は事前に教えない。

Maze 15x15 | seed=19 | geDIG | steps=44



因果: ゴールを教えるのではなく、移動履歴から候補分布を作る → F で記憶接続を選択 → 疎な認知地図で戻る/進む判断が可能。

6 Maze 結果: 成功率より「記憶圧縮」を見る


手法	成功率	平均 step	圧縮率
15×15 (n=100, max=250)			
Random Walk	0.75 ± 0.08	105.8	-
Greedy DFS	0.99 ± 0.03	82.1	-
geDIG	0.98 ± 0.03	89.6	98%
25×25 (n=60, max=500)			
Random Walk	0.40 ± 0.12	242.2	-
Greedy DFS	0.95 ± 0.06	242.2	-
geDIG	0.75 ± 0.11	254.1	99%

25×25 では Greedy DFS の成功率が高い。geDIG の主張は、候補エッジの大半を棄却しても到達可能性を保つことに置く。

7 共通グラフ化: 何をノード/エッジにするか

対象	ノード	エッジ	F が判定するもの
Maze	移動エピソード	通行/想起接続	この接続を記憶へ残すか
Transformer	トークン	Attention	層が探索相か構造相か
Sleep	既存記憶ノード	再配線候補	入力なしで整理すべきか

8 Transformer: 同じ F が意味的 KG にも現れる



Attention 行列を token-relation graph として扱うと、浅層は高エントロピーな探索相、深層は低エントロピーな構造相として読める。

観測: 層別 F の遷移は p < 10⁻⁸⁰。F 正則化は弱いと改善し、強すぎると性能を落とす。

α	Accuracy	Δ
0	86.00 ± 0.53	-
0.001	86.33 ± 0.46	+0.33
0.01	86.27 ± 0.70	+0.27
0.1	85.93 ± 1.10	-0.07
1.0	78.93 ± 1.55	-7.07

9 考察: 操作的対応としての FEP/MDL

ΔEPC は複雑さ、ΔH は探索余地、ΔSP は構造利得に対応する。これは KL と GED の厳密同値を主張するものではなく、グラフ上で計算可能な操作的対応である。

また、F の構成項はグラフ内部状態から計算可能である。ただし Transformer の性能評価や CE 学習にはタスクラベルを用いる。

10 今後の展望: Wake から Sleep へ

Wake: 入力評価

本論文の範囲。新規入力 came とき、AG/DG で探索・統合・棄却を判定する。

- Maze: 移動エピソードを評価
- Transformer: Attention構造を評価

Sleep: 入力なしの整理

現在の記憶グラフ自身から再編候補を生成し、ΔF < 0 の整理だけを採択する。

- 冗長エッジ削除
- クラスタ統合・近道保持

B1 / 位相拡張

提出版の ΔSP を、発展版では β₁ (B1) に拡張し、ループ/短絡を位相量として扱う。

- GraphRAG / Self-RAG への適用
- Wake/Sleep 両方で自律整理を制御

Email
miyauchikazuyoshi@gmail.com



Landing page
miyauchikazuyoshi.github.io/InsightSpike-AI/



GitHub
github.com/miyauchikazuyoshi/InsightSpike-AI

