

動的知識グラフの探索・統合を制御する統一ゲージの提案 —Gauge what Knowledge Graph needs.—

A Unified Gauge for Controlling Exploration and Integration in Dynamic Knowledge Graphs
— Gauge what Knowledge Graph needs. —

宮内 和義^{*1}

Kazuyoshi Miyauchi

^{*1}独立研究者

Independent Researcher

Dynamic knowledge graphs face a fundamental “When” problem: when to accept new information as structure, and when to continue exploration. We propose **geDIG**, a unified gauge that quantifies this trade-off as $\mathcal{F} = \Delta\text{EPC}_{\text{norm}} - \lambda(s \cdot \Delta H_{\text{norm}} + \gamma \Delta\text{SP})$. In this work, we improve geDIG for Transformers by (1) redefining **Shortcut Purity (SP)** as path concentration to anchor tokens (CLS), solving the dilution problem in all-pairs reachability, and (2) introducing **entropy_sign (s)** to adapt the interpretation based on learning phase. We validate geDIG on two instantiations: (1) **Spatial KG (Maze)**: An agent achieves 98% success rate while rejecting 98% of candidate edges. (2) **Semantic KG (Transformer)**: Intervention experiments show that Positive intervention (promoting $\mathcal{F} \downarrow$) outperforms Negative intervention by 4.6% accuracy, demonstrating that geDIG $\mathcal{F}$ is a valid learning signal. These results suggest geDIG as a general-purpose gauge for controlling exploration and integration across domains.

1. はじめに

動的知識グラフ (Dynamic Knowledge Graph) において、新しい情報を「いつ」構造として受け入れ、「いつ」探索を続けるべきか——この **When 問題** は未解決の基本課題である。本研究では、自由エネルギー原理 (FEP) [1] と最小記述長 (MDL) [2] を操作的に橋渡しする統一評価関数 **geDIG** (graph edit Distance and Information Gain) を提案し、この問題に原理的な解を与える。

geDIG の核心的仮説は、「構造コストと情報利得のトレードオフを単一スカラーで評価すれば、知識グラフの種類によらず、探索と統合を統一的に制御できる」というものである。本稿では、geDIG を迷路と Transformer で検証する。特に、Transformer 適用における課題を解決する 2 つの改良を提案する：

1. **SP 定義の改善**: 全ペア到達性からアンカー (CLS) への経路集中度へ
2. **entropy_sign 導入**: 学習フェーズに応じた解釈の切替

2. geDIG: 統一評価関数の定義

geDIG は、「構造を変えるコスト」と「それによって得られる情報の質」の収支を単一スカラー $\mathcal{F}$ で評価する。

$$\mathcal{F} = \Delta\text{EPC}_{\text{norm}} - \lambda(s \cdot \Delta H_{\text{norm}} + \gamma \cdot \Delta\text{SP}) \quad (1)$$

各項の意味は：

- $\Delta\text{EPC}_{\text{norm}}$: 構造変更コスト (グラフ編集距離の正規化値)
- ΔH_{norm} : エントロピー変化 (選択枝の多様性)
- ΔSP : 経路効率の変化 (ショートカット形成)
- s : entropy_sign. 学習フェーズに応じて ± 1 を取る (後述)

具体的な計算方法はドメインごとに異なり、各実験セクションで定義する。

連絡先: miyauchikazuyoshi@gmail.com




図 1: AG/DG 制御フロー。AG は局所的異常 (高 $\mathcal{F}$) を, DG は大域的効率化 (低 $\mathcal{F}$) を検知する。

2.1 entropy_sign (s) パラメータ

迷路と Transformer では初期状態が異なる：

- **迷路**: 空グラフから開始し, エントロピーを獲得していく ($H: 0 \rightarrow \text{増加}$)
- **Transformer (事前学習済み)**: 既に構造化された状態から開始し, タスク特化のため集中化する ($H: \text{中} \rightarrow \text{減少}$)

この違いに対応するため, s (entropy_sign) を導入する：

- $s = +1$ (基本): エントロピー増加 (延伸) が利得
- $s = -1$ (Fine-tuning): エントロピー減少 (集中) が利得

2.2 AG/DG 二段ゲート制御

この $\mathcal{F}$ を用いて, エージェントは以下の 2 つのゲートを制御する。


1. **AG (Attention Gate)**: 0-hop 評価. $g_0 > \theta_{\text{AG}}$ のとき探索を起動。
2. **DG (Decision Gate)**: Multi-hop 評価. $g_{\text{min}} < \theta_{\text{DG}}$ のとき統合を実行。

3. 検証 I: 空間的 KG としての迷路探索


KG としての定式化 部分観測迷路におけるエージェントの認知地図は、動的知識グラフの一形態である。ノードは訪問した位置、エッジは移動可能な接続を表す。

表 1: 迷路ナビゲーション結果

手法	成功率	平均ステップ	圧縮率
15×15 ($n = 100$)			
Random Walk	0.75 ± 0.08	105.8 ± 63.9	–
Greedy DFS	0.99 ± 0.03	82.1 ± 30.8	–
geDIG	0.98 ± 0.03	89.6 ± 44.8	98%
25×25 ($n = 60$)			
Random Walk	0.40 ± 0.12	242.2 ± 143.7	–
geDIG	0.75 ± 0.11	254.1 ± 125.4	99%



(a) 実空間の探索軌跡



(b) 抽象化された内部表現

図 2: 迷路探索における実空間と内部表現の対応. 直線通路は圧縮され, 分岐点のみが保持される.

geDIG 成分の定義 (迷路)

- ΔEPC_{norm} : エッジ追加数 / 正規化定数. 新しいエッジを追加するコスト.
- ΔH : 候補集合の類似度分布のエントロピー. 各候補 (次の行動先) に対する類似度を確率分布とし, シャノンエントロピーを計算. $\Delta H > 0$ は選択肢の多様性増加を表す.
- ΔSP : 平均最短経路長の相対短縮率. $\Delta SP = (L_{\text{before}} - L_{\text{after}}) / L_{\text{before}}$. エッジ追加によりショートカットが形成されると $\Delta SP > 0$ となる.

仮説geDIG の AG/DG ゲートにより, 高い成功率を維持しつつ, 候補エッジの大半を棄却する効率的な記憶構築が可能である.

実験設定 15×15 および 25×25 の迷路を用いた. パラメータは $\lambda = 1.0, \gamma = 1.0, \theta_{\text{AG}} = 0.4, \theta_{\text{DG}} = 0.0$. 比較対象は Random Walk と Greedy DFS.

3.1 結果: 探索と統合の自律制御

geDIG エージェントは, Random Walk を有意に上回り (McNemar 検定, $p < 10^{-5}$), 候補エッジの 98% を棄却しながら高い成功率を達成した (表 1).

4. 検証 II: 意味的 KG としての Transformer

KG としての定式化 Transformer の Attention 行列 A_{ij} は, トークン間の「関係の強さ」を表す. これを閾値処理してグラフ化すると, 意味的 KG が得られる.

geDIG 成分の定義 (Transformer)

- ΔEPC_{norm} : Attention 重みの有意な変化量. 閾値以上の変化をカウント.

表 2: 介入実験結果 (SST-2, DistilBERT, $s = -1$)

条件	精度	mean_F	mean_SP
Baseline	86.8%	2.13	0.80
Positive	85.6%	1.77	0.99
Negative	81.0%	0.63	0.71

Positive > Negative: 4.6%差

- ΔH : **Attention 分布のエントロピー**. 各クエリトークンの attention 分布からシャノンエントロピーを計算. $\Delta H < 0$ は特定トークンへの集中を表す.
- ΔSP : **CLS への経路集中度** (下記で詳述).

4.1 SP (Shortcut Purity) の再定義

従来の SP 定義 (全ペア到達性) は, Transformer では意味が希釈される問題があった. 本研究では, **アンカートークン (CLS) への経路集中度**として SP を再定義する:

$$SP = \frac{\sum_{\text{top-}k} A_{i \rightarrow \text{CLS}}}{\sum_{\text{all}} A_{i \rightarrow \text{CLS}}} \quad (2)$$

ここで, 上位 $k\%$ の経路が全体に占める割合を測定する. 高い SP 値は「少数の強い経路」(効率的なショートカット) を, 低い SP 値は「多数の弱い経路」(ノイズ) を表す.

迷路との対応 両ドメインで SP は「効率的な経路形成」を測定する:

- 迷路: 平均最短経路長の短縮 (ショートカット発見)
- Transformer: CLS への情報集約の効率化

4.2 実験設定

モデル・タスク DistilBERT, SST-2 感情分類. 訓練 2000 サンプル, 評価 500 サンプル.

介入方法 geDIG $\mathcal{F}$ に基づく正則化を適用:

- **Positive 介入**: $\mathcal{F} \downarrow$ 方向 (SP $\uparrow$ を促進)
- **Negative 介入**: $\mathcal{F} \uparrow$ 方向 (SP $\downarrow$ を促進)
- **Baseline**: 正則化なし

entropy_sign $s = -1$ (Fine-tuning 用), $\alpha = 0.1$, 2 エポック.

4.3 結果: geDIG $\mathcal{F}$ が学習方向を予測

表 2 に示すように, **Positive 介入が Negative 介入を 4.6% 上回った**. これは, geDIG $\mathcal{F}$ が有効な学習シグナルであることを因果的に示している.

SP 変化の観察 Positive 介入では SP が 0.80→0.99 に増加 (CLS への経路集中), Negative 介入では 0.80→0.71 に減少した. これは, SP 定義が Transformer の学習ダイナミクスを正しく捉えていることを示す.

4.4 観測: 層別の構造相転移

図 3 に BERT の層別 geDIG $\mathcal{F}$ 値の分布を示す. geDIG v2 (SP=CLS への経路集中度) で分析した結果:

- **浅層 (0-2)**: 分散が大きく中央値は約 7. 多様な注意パターンが混在.
- **深層 (5-11)**: 中央値が約 9 に上昇し, 外れ値 (低 $\mathcal{F}$) が出現. 構造化が進む一方, 一部サンプルで効率的な経路が形成される.

この結果は, Transformer が層方向に「探索 → 構造化」の相転移を行っていることを示唆する.




図 3: BERT における層別 geDIG F 値の分布 (geDIG v2, $s = -1$, $n = 100$)。浅層で分散が大きく中央値が低い一方、深層では中央値が上昇し外れ値（低 F）が出現する。

5. 考察とおわりに

本研究では、2 種類の動的 KG——空間的 KG（迷路）と意味的 KG（Attention）——において、geDIG 評価関数 $\mathcal{F}$ が共通の「構造化原理」として機能することを示した。

v2 からの主な改良

1. **SP 定義**：全ペア到達性 → アンカーへの経路集中度
2. **entropy_sign**：学習フェーズに応じた解釈の切替
3. **介入実験**：Positive > Negative で因果関係を実証

迷路と Transformer の対応両ドメインに共通するのは、「構造とエントロピーのトレードオフで最適な経路効率に収束する」というプロセスである。迷路ではゴールへのショートカット形成、Transformer では CLS への情報集約として現れる。

構造生成としての学習従来のニューラルネットワーク学習は「重みの最適化」として定式化されてきた。一方、geDIG の視点では、学習は「グラフ構造の生成」として捉え直せる。重み更新の結果として Attention パターンが変化し、それが KG のエッジ追加・削除に対応する。この視点は、学習を「与えられた損失関数の最小化」から「内部構造の自律的組織化」へと再解釈する可能性を示唆する。

内発報酬としての geDIGgeDIG $\mathcal{F}$ は外部の正解ラベルを必要とせず、ネットワーク内部の状態のみから計算できる。これは、 $\mathcal{F}$ が内発報酬 (intrinsic reward) として機能しうることを意味する。迷路実験では、ゴール到達という外部報酬なしに、 $\mathcal{F}$ の最小化のみでナビゲーションが成立した。この性質は、自己教師あり学習や継続学習への応用可能性を示唆する。

限界と今後の展望本研究は事前学習済みモデルの Fine-tuning のみを検証した。今後は、Pythia[7] のチェックポイントを用いて、ランダム初期化からの学習過程全体 ($H: \max \rightarrow \text{optimal}$) を観察し、geDIG の適用範囲を拡大する予定である。

参考文献

- [1] Friston, K.: The free-energy principle: a unified brain theory?, Nat. Rev. Neurosci., 11, 127–138 (2010).
- [2] Grünwald, P. D.: The Minimum Description Length Principle, MIT Press (2007).
- [3] Vaswani, A., et al.: Attention Is All You Need, NeurIPS (2017).

- [4] O’Keefe, J., Nadel, L.: The Hippocampus as a Cognitive Map, Oxford University Press (1978).
- [5] Devlin, J., et al.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, NAACL (2019).
- [6] Bunke, H.: On a relation between graph edit distance and maximum common subgraph, Pattern Recognition Letters, 18(8), 689–694 (1997).
- [7] Biderman, S., et al.: Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling, ICML (2023).